Importando dataset

```
import kagglehub

# Download latest version
path = kagglehub.dataset_download("yasserh/titanic-dataset")

print("Path to dataset files:", path)
```

```
Using Colab cache for faster access to the 'titanic-dataset' dataset.
Path to dataset files: /kaggle/input/titanic-dataset
```

Processando e limpando dataset

```
import pandas as pd
```

```
df = pd.read_csv("/kaggle/input/titanic-dataset/Titanic-Dataset.csv")
df.head()
```

	PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
0	1	0	3	Braund, Mr. Owen Harris	male	22.0	1	0	A/5 21171	7.2500	NaN	S
1	2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Th...	female	38.0	1	0	PC 17599	71.2833	C85	C
2	3	1	3	Heikkinen, Miss. Laina	female	26.0	0	0	STON/O2. 3101282	7.9250	NaN	S

Próximas etapas: Gerar código com df | New interactive sheet

```
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 12 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   PassengerId  891 non-null    int64
 1   Survived     891 non-null    int64
 2   Pclass       891 non-null    int64
 3   Name         891 non-null    object
 4   Sex          891 non-null    object
 5   Age          714 non-null    float64
 6   SibSp        891 non-null    int64
 7   Parch        891 non-null    int64
 8   Ticket       891 non-null    object
 9   Fare         891 non-null    float64
 10  Cabin        204 non-null    object
 11  Embarked     889 non-null    object
dtypes: float64(2), int64(5), object(5)
memory usage: 83.7+ KB
```

```
df.describe()
```

	PassengerId	Survived	Pclass	Age	SibSp	Parch	Fare
count	891.000000	891.000000	891.000000	714.000000	891.000000	891.000000	891.000000
mean	446.000000	0.383838	2.308642	29.699118	0.523008	0.381594	32.204208
std	257.353842	0.486592	0.836071	14.526497	1.102743	0.806057	49.693429
min	1.000000	0.000000	1.000000	0.420000	0.000000	0.000000	0.000000
25%	223.500000	0.000000	2.000000	20.125000	0.000000	0.000000	7.910400
50%	446.000000	0.000000	3.000000	28.000000	0.000000	0.000000	14.454200
75%	668.500000	1.000000	3.000000	38.000000	1.000000	0.000000	31.000000
max	891.000000	1.000000	3.000000	80.000000	8.000000	6.000000	512.329200

```
Comece a programar ou gere código com IA.
```

```
#Removendo colunas
df_aux = df
df_aux = df_aux.drop(columns=['Name', 'Cabin', 'Ticket', 'PassengerId'])
df_aux.head()
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	0	3	male	22.0	1	0	7.2500	S
1	1	1	female	38.0	1	0	71.2833	C
2	1	3	female	26.0	0	0	7.9250	S
3	1	1	female	35.0	1	0	53.1000	S
4	0	3	male	35.0	0	0	8.0500	S

Próximas etapas: Gerar código com df_aux | New interactive sheet

```
df_aux['Embarked'].value_counts()
```

Embarked	count
S	644
C	168
Q	77

dtype: int64

```
#Substituindo pelo object que mais aparece
df_aux['Embarked'] = df_aux['Embarked'].fillna(df_aux['Embarked'].mode()[0])
```

```
df_aux['Embarked'].value_counts()
```

Embarked	count
S	646
C	168
Q	77

dtype: int64

```
#Substituindo os valores nulos pela média da idade
df_aux['Age'] = df_aux['Age'].fillna(df_aux['Age'].mean())
#Transformando os valores de float para int
df_aux['Age'] = df_aux['Age'].astype(int)
df_aux.head()
```

	Survived	Pclass	Sex	Age	SibSp	Parch	Fare	Embarked
0	0	3	male	22	1	0	7.2500	S
1	1	1	female	38	1	0	71.2833	C
2	1	3	female	26	0	0	7.9250	S
3	1	1	female	35	1	0	53.1000	S
4	0	3	male	35	0	0	8.0500	S

Próximas etapas: Gerar código com df_aux | New interactive sheet

```
#Transforma a classe 'Sex' em encoding
df_aux['Sex'].isnull().sum()
sex_dummies = pd.get_dummies(df_aux['Sex'], prefix='Sex')
df_aux = pd.concat([df_aux, sex_dummies], axis=1)
df_aux = df_aux.drop(columns=['Sex'])
df_aux.head()
```

	Survived	Pclass	Age	SibSp	Parch	Fare	Embarked	Sex_female	Sex_male
0	0	3	22	1	0	7.2500	S	False	True
1	1	1	38	1	0	71.2833	C	True	False
2	1	3	26	0	0	7.9250	S	True	False
3	1	1	35	1	0	53.1000	S	True	False
4	0	3	35	0	0	8.0500	S	False	True

Próximas etapas: Gerar código com df_aux | New interactive sheet

```
#Transforma a classe "Embarked" em encoding
df_aux['Embarked'].isnull().sum()
embarked_dummies = pd.get_dummies(df_aux['Embarked'], prefix='Embarked')
df_aux = pd.concat([df_aux, embarked_dummies], axis=1)
df_aux = df_aux.drop(columns=['Embarked'])
df_aux.head()
```

	Survived	Pclass	Age	SibSp	Parch	Fare	Sex_female	Sex_male	Embarked_C	Embarked_Q	Embarked_S
0	0	3	22	1	0	7.2500	False	True	False	False	True
1	1	1	38	1	0	71.2833	True	False	True	False	False
2	1	3	26	0	0	7.9250	True	False	False	False	True
3	1	1	35	1	0	53.1000	True	False	False	False	True
4	0	3	35	0	0	8.0500	False	True	False	False	True

Próximas etapas: Gerar código com df_aux | New interactive sheet

```
#Criando nova coluna para simplifica 'SibSp' e 'Parch'
df_aux['FamilySize'] = df_aux['SibSp'] + df_aux['Parch'] + 1
df_aux = df_aux.drop(columns=['SibSp', 'Parch'])
df_aux.head()
```

	Survived	Pclass	Age	Fare	Sex_female	Sex_male	Embarked_C	Embarked_Q	Embarked_S	FamilySize
0	0	3	22	7.2500	False	True	False	False	True	2
1	1	1	38	71.2833	True	False	True	False	False	2
2	1	3	26	7.9250	True	False	False	False	True	1
3	1	1	35	53.1000	True	False	False	False	True	2
4	0	3	35	8.0500	False	True	False	False	True	1

Próximas etapas: Gerar código com df_aux | New interactive sheet

```
#Criando coluna para sabe se a pessoa estava acomponhado ou não
df_aux['IsAlone'] = df_aux['FamilySize'].apply(lambda x: 1 if x == 1 else 0)
df_aux = df_aux.drop(columns=['FamilySize'])
df_aux.head()
```

	Survived	Pclass	Age	Fare	Sex_female	Sex_male	Embarked_C	Embarked_Q	Embarked_S	IsAlone
0	0	3	22	7.2500	False	True	False	False	True	0
1	1	1	38	71.2833	True	False	True	False	False	0
2	1	3	26	7.9250	True	False	False	False	True	1
3	1	1	35	53.1000	True	False	False	False	True	0
4	0	3	35	8.0500	False	True	False	False	True	1

Próximas etapas: Gerar código com df_aux | New interactive sheet

```
bool_cols = df_aux.select_dtypes(include='bool').columns
df_aux[bool_cols] = df_aux[bool_cols].astype(int)
df_aux.head()
```

	Survived	Pclass	Age	Fare	Sex_female	Sex_male	Embarked_C	Embarked_Q	Embarked_S	IsAlone
0	0	3	22	7.2500	0	1	0	0	1	0
1	1	1	38	71.2833	1	0	1	0	0	0
2	1	3	26	7.9250	1	0	0	0	1	1
3	1	1	35	53.1000	1	0	0	0	1	0
4	0	3	35	8.0500	0	1	0	0	1	1

Próximas etapas: Gerar código com df_aux | New interactive sheet

```
df_aux['Fare'].isnull().sum()
```

```
np.int64(0)
```

Análise Exploratória (EDA)

```
porcentagem = df_aux['Survived'].mean()
print(f'Apenas {round(df_aux['Survived'].mean() * 100, 2)}% sobreviveram.' )
```

```
Apenas 38.38% sobreviveram.
```

```
df_aux.groupby('Sex_female')['Survived'].mean()
print(f'Apenas {round(df_aux.groupby("Sex_female")["Survived"].mean()[1] * 100, 2)}% das mulheres sobreviveram.')
print(f'Apenas {round(df_aux.groupby("Sex_female")["Survived"].mean()[0] * 100, 2)}% dos homens sobreviveram.')
```

```
Apenas 74.2% das mulheres sobreviveram.
Apenas 18.89% dos homens sobreviveram.
```

```
df_aux.groupby('Pclass')['Survived'].mean()
print(f'Observa-se uma forte correlação entre classe social e taxa de sobrevivência. Passageiros da 1ª classe apresentaram
```

```
Observa-se uma forte correlação entre classe social e taxa de sobrevivência. Passageiros da 1ª classe apresentaram maior prc
```

```
df_aux.groupby('IsAlone')['Survived'].mean()
```

IsAlone	Survived
0	0.505650
1	0.303538

dtype: float64

```
df_aux['AgeGroup'] = pd.cut(
    df_aux['Age'],
    bins=[0, 12, 18, 40, 60, 100],
    labels=['Criança', 'Adolescente', 'Adulto', 'Meia-idade', 'Idoso']
)
df_aux.groupby('AgeGroup')['Survived'].mean()
```

```
/tmp/ipykernel_25128/3233601164.py:6: FutureWarning: The default of observed=False is deprecated and will be changed to True
  df_aux.groupby('AgeGroup')['Survived'].mean()
```

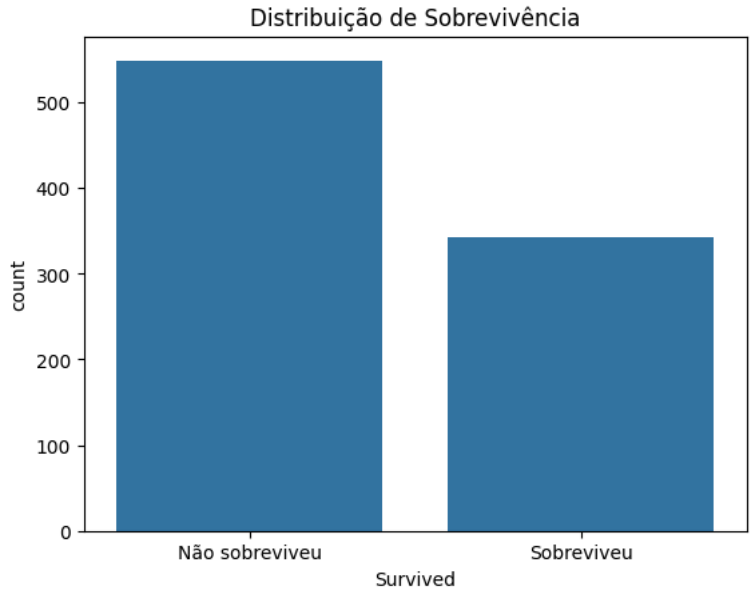
AgeGroup	Survived
Criança	0.532258
Adolescente	0.428571
Adulto	0.359272
Meia-idade	0.396825
Idoso	0.227273

dtype: float64

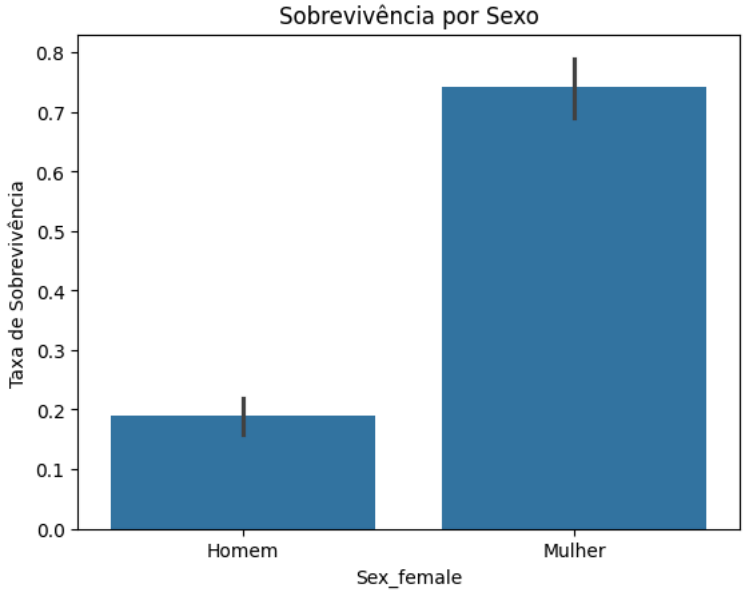
Gráficos

```
import seaborn as sns
import matplotlib.pyplot as plt

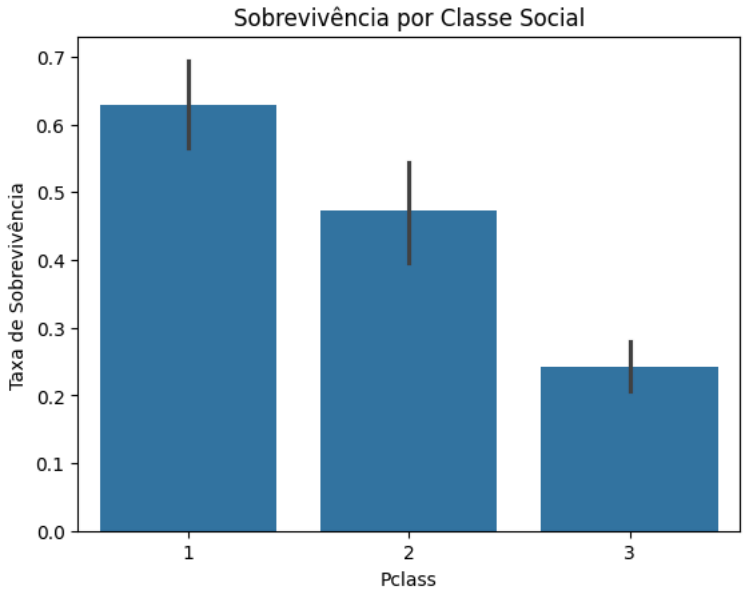
sns.countplot(x='Survived', data=df_aux)
plt.xticks([0,1], ['Não sobreviveu', 'Sobreviveu'])
plt.title('Distribuição de Sobrevivência')
plt.show()
```



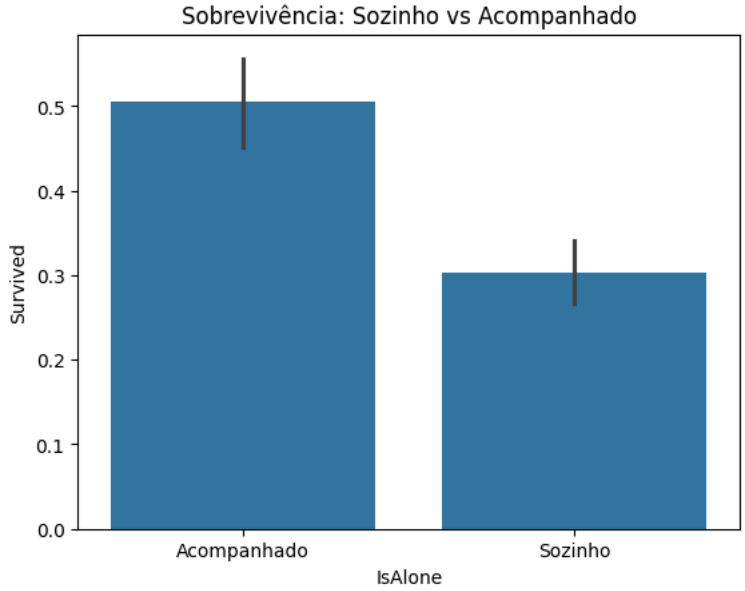

```
sns.barplot(x='Sex_female', y='Survived', data=df_aux)
plt.xticks([0,1], ['Homem', 'Mulher'])
plt.title('Sobrevivência por Sexo')
plt.ylabel('Taxa de Sobrevivência')
plt.show()
```



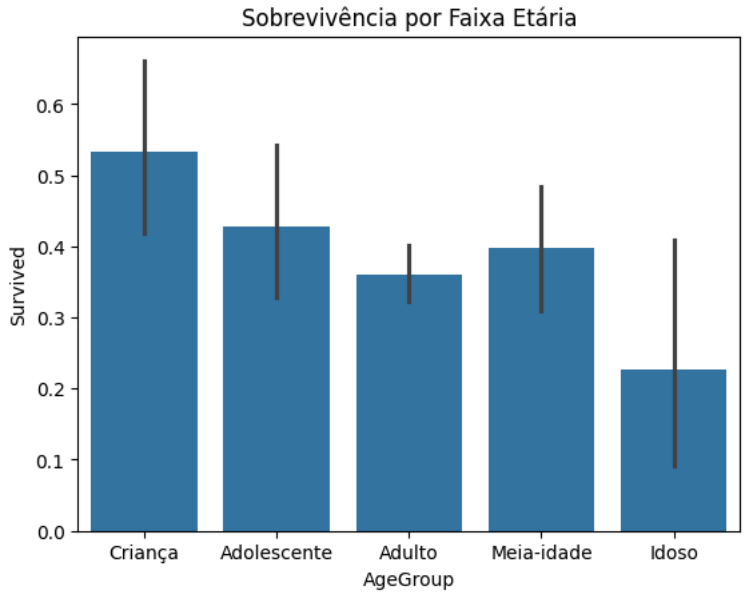

```
sns.barplot(x='Pclass', y='Survived', data=df_aux)
plt.title('Sobrevivência por Classe Social')
plt.ylabel('Taxa de Sobrevivência')
plt.show()
```



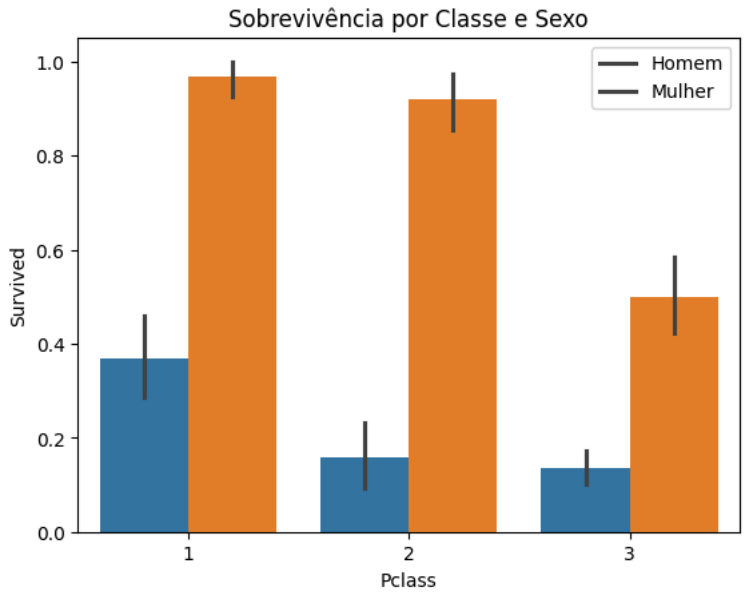

```
sns.barplot(x='IsAlone', y='Survived', data=df_aux)
plt.xticks([0,1], ['Acompanhado', 'Sozinho'])
plt.title('Sobrevivência: Sozinho vs Acompanhado')
plt.show()
```




```
sns.barplot(x='AgeGroup', y='Survived', data=df_aux)
plt.title('Sobrevivência por Faixa Etária')
plt.show()
```



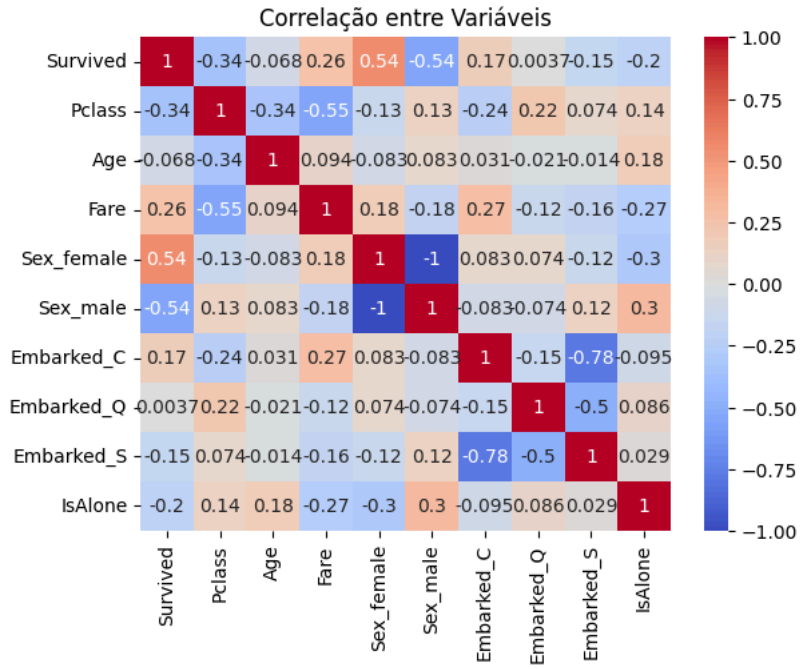

```
sns.barplot(x='Pclass', y='Survived', hue='Sex_female', data=df_aux)
plt.legend(['Homem', 'Mulher'])
plt.title('Sobrevivência por Classe e Sexo')
plt.show()
```



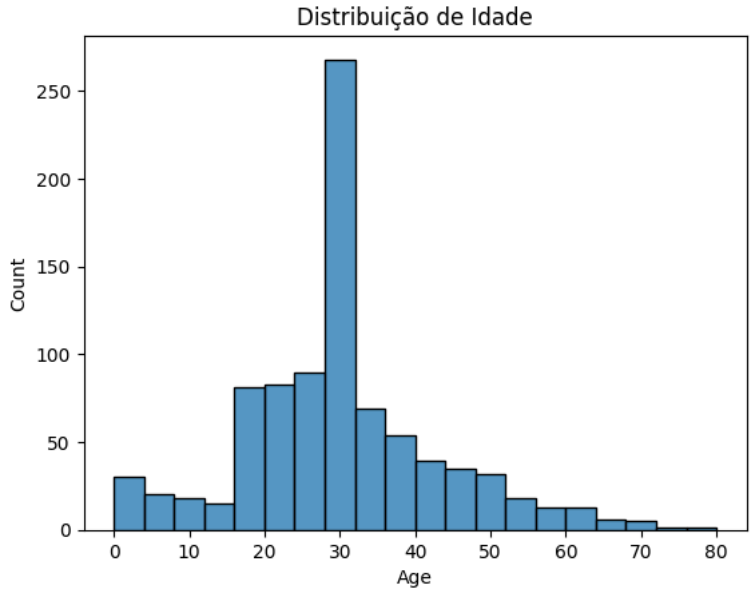

```
import numpy as np

corr = df_aux.corr(numeric_only=True)

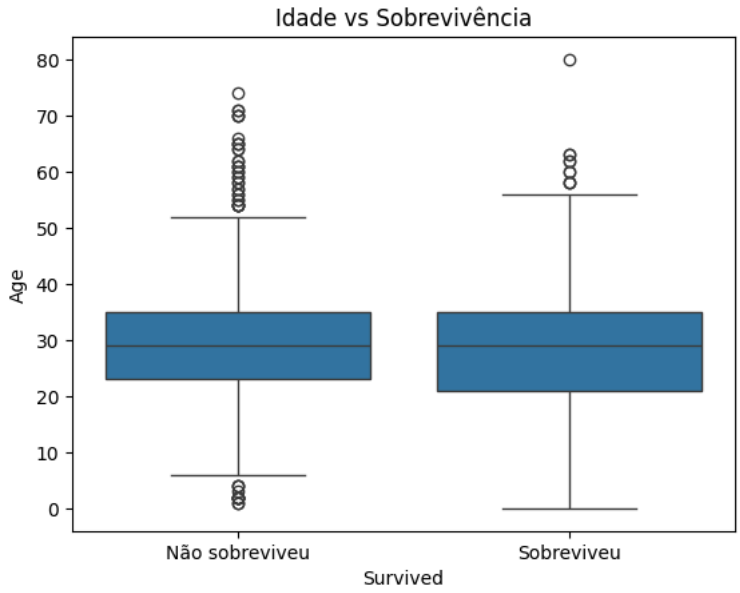
sns.heatmap(corr, annot=True, cmap='coolwarm')
plt.title('Correlação entre Variáveis')
plt.show()
```




```
sns.histplot(df_aux['Age'], bins=20)
plt.title('Distribuição de Idade')
plt.show()
```




```
sns.boxplot(x='Survived', y='Age', data=df_aux)
plt.xticks([0,1], ['Não sobreviveu', 'Sobreviveu'])
plt.title('Idade vs Sobrevivência')
plt.show()
```



Análise Exploratória de Dados do Dataset Titanic

Resumo

Este estudo apresenta uma análise exploratória de dados (EDA) aplicada ao dataset Titanic, com o objetivo de identificar os principais fatores que influenciaram a sobrevivência dos passageiros. Foram realizadas etapas de pré-processamento, engenharia de atributos, análise estatística e visualizações gráficas. Os resultados indicam que variáveis como sexo, classe social e presença de familiares tiveram impacto significativo na probabilidade de sobrevivência, enquanto a idade apresentou influência moderada.

---

1. Introdução

O naufrágio do Titanic é um dos eventos históricos mais estudados em ciência de dados, sendo amplamente utilizado para análise preditiva e exploração de padrões. Este trabalho busca compreender quais características dos passageiros influenciaram suas chances de sobrevivência, utilizando técnicas de análise exploratória de dados.

---

2. Metodologia

O processo de análise foi dividido em cinco etapas principais:

2.1 Importação dos Dados

Os dados foram carregados em um DataFrame utilizando a biblioteca Pandas, contendo variáveis como idade, sexo, classe, tarifa e status de sobrevivência.

2.2 Limpeza e Pré-processamento

Nesta etapa, foram realizadas transformações para preparar os dados para análise:

- Conversão de variáveis categóricas em numéricas utilizando One-Hot Encoding (ex: sexo e porto de embarque).
- Remoção de colunas irrelevantes.
- Conversão de valores booleanos para inteiros.

2.3 Engenharia de Atributos

Foram criadas novas variáveis para enriquecer a análise:

- **FamilySize**: soma do número de familiares a bordo.
- **IsAlone**: variável binária indicando se o passageiro estava sozinho.
- **AgeGroup**: categorização da idade em faixas (criança, adolescente, adulto, meia-idade e idoso).

2.4 Análise Exploratória de Dados (EDA)

Foram utilizadas estatísticas descritivas e agrupamentos (`groupby`) para identificar padrões entre variáveis e a sobrevivência.

2.5 Visualização de Dados

Gráficos foram gerados com as bibliotecas Seaborn e Matplotlib, incluindo:

- Gráficos de contagem
- Gráficos de barras
- Heatmap de correlação
- Histogramas e boxplots

---

3. Resultados

A análise revelou os seguintes padrões:

3.1 Taxa Geral de Sobrevivência

Apenas aproximadamente **38,38%** dos passageiros sobreviveram ao desastre.

3.2 Influência do Sexo

Observou-se uma diferença significativa entre os sexos:

- Mulheres: aproximadamente **74%** sobreviveram
- Homens: aproximadamente **19%** sobreviveram

Isso sugere a aplicação do protocolo de prioridade para mulheres e crianças.

3.3 Influência da Classe Social

A classe do passageiro apresentou forte relação com a sobrevivência:

- 1ª classe: maior taxa de sobrevivência (~63%)
- 3ª classe: menor taxa (~24%)

Esse resultado evidencia a influência de fatores socioeconômicos.